

Алгоритмы оптимизации на основе неспектральных матричных норм для обучения нейронных сетей


Алексей Юрьевич Кравацкий

Научный руководитель: д.ф.-м.н., проф. РАН И. В. Оселедец


Кафедра интеллектуальных систем ФПМИ МФТИ

Специализация: Интеллектуальный анализ данных

Направление: 03.03.01 Прикладные математика и физика



2026



Неспектральные матричные нормы для обучения нейронных сетей

Проблема

Поиск $\arg \min_{\mathbf{X} \in \mathbb{R}^{m \times n}} f(\mathbf{X})$, в особенности когда $\mathbf{X}$ — матрица весов в нейронной сети, а f невыпуклая.

Цель

В рамках подхода **norm-constrained linear minimization oracle** (LMO) (Pethick и др., 2025b) **отойти от спектральной нормы**, чтобы получить эффективные алгоритмы для обучения внутренних слоёв нейросети взамен Muon.

Решение

На основе норм Ки Фана предлагается построить матричные нормы, порождающие семейства алгоритмов *Fanions*, связанные с Muon, ν -SAM и Dion, а также *F-Fanions* и *S-Fanions*, объединяющие Fanions с **Normalized SGD (NSGD) и SignSGD**.

Norm-constrained LMO: задача выбора нормы

Наделим пространство $\mathbb{R}^{m \times n}$ нормой $\|\cdot\|$ с единичным шаром $\mathcal{B}_1 = \{\mathbf{D} \in \mathbb{R}^{m \times n} \mid \|\mathbf{D}\| \leq 1\}$. Её двойственная норма определяется как $\|\mathbf{M}\|^\dagger = \sup_{\mathbf{D} \in \mathcal{B}_1} \langle \mathbf{M}, \mathbf{D} \rangle$.

Направление $\text{LMO}(\mathbf{M}^t) \in \text{Arg min}_{\mathbf{D} \in \mathcal{B}_1} \langle \mathbf{M}^t, \mathbf{D} \rangle$, где $\mathbf{M}^t$ — градиент или моментум, задаёт обновление:

$$\begin{aligned} \mathbf{X}^{t+1} &= \mathbf{X}^t + \gamma_t \text{LMO}(\mathbf{M}^t) \in \mathbf{X}^t - \gamma_t \underset{\mathbf{D} \in \mathcal{B}_1}{\text{Arg max}} \langle \mathbf{M}^t, \mathbf{D} \rangle \\ &= \mathbf{X}^t - \gamma_t \{\Delta \in \mathcal{B}_1 \mid \langle \mathbf{M}^t, \Delta \rangle = \|\mathbf{M}^t\|^\dagger\}. \end{aligned}$$

Достаточно найти направление $\Delta \in \mathcal{B}_1$, которое даёт равенство $\langle \mathbf{M}^t, \Delta \rangle = \|\mathbf{M}^t\|^\dagger$. Для этого часто требуется SVD разложение: $\mathbf{M}^t = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^\top = \mathbf{U} \text{diag}(\sigma_1, \dots, \sigma_r) \mathbf{V}^\top$.

Требуется

Выяснить, какие $\|\cdot\|$, помимо спектральной $\|\cdot\|_{\text{op}}$, задают эффективные на практике алгоритмы.

LMO-алгоритмы в нормах Шаттена S_p и векторных l_p нормах

Метод	$\ \cdot\ $ для LMO	Обновление LMO	Ссылка
Normalized SGD	Евклидова l_2 /	$-\gamma_t \frac{g}{\ g\ _2} = -\gamma_t \frac{g}{\ g\ _F}$	(Hazan и др., 2015)
Momentum Normalized SGD	Фробениусова S_2	$-\gamma_t \frac{g}{\ g\ _2} = -\gamma_t \frac{g}{\ g\ _F}$	(Cutkosky и др., 2020)
SignSGD	l_∞ (Мак-норма)	$-\gamma_t \text{sign}(g)$	(Bernstein и др., 2018)
Signum	l_∞ (Мак-норма)	$-\gamma_t \text{sign}(g)$	(Bernstein и др., 2018)
Muon	Спектральная S_∞	$-\gamma_t UV^\top$	(Jordan и др., 2024)
Gauss-Southwell Descent	Шар в l_1	$-\gamma_t \sum_{i \in \arg \max g_i^t } \text{sign}(g_i^t) e_i$	(Shi и др., 2016)
Neon	Ядерная S_1	$-\gamma_t u_1 v_1^\top$	(Kravatskiy и др., 2025)
ν SAM	Ядерная S_1		(Pethick и др., 2025a)

Проблема ранга LMO-обновлений

Нормы Шаттена $\|M^t\|_{S_p} = \left(\sum_{i=1}^{\min(m,n)} \sigma_i^p\right)^{1/p}$ дают шаг обновления

$$X^{t+1} = X^t - \gamma_t U \frac{\text{diag}\left(\sigma_1^{q-1}, \dots, \sigma_{\min(m,n)}^{q-1}\right)}{\left(\sum_{i=1}^{\min(m,n)} \sigma_i^q\right)^{\frac{q-1}{q}}} V^\top$$

где $p^{-1} + q^{-1} = 1$ (Cesista, 2025).

Нормы Ки Фана $\|M^t\|_{\text{KF-k}} = \sum_{i=1}^k \sigma_i$ дают

$$X^{t+1} = X^t - \gamma_t u_1 v_1^\top \quad \text{или} \quad X^{t+1} = X^t - \frac{\gamma_t}{k} UV^\top,$$

что соответствует алгоритмам Neon или Muon (Kravatskiy и др., 2025).

Следствие: обновления получаются либо одноранговыми, либо полноранговыми.

Нормы $\|\cdot\|_{\text{KF}-k}^\dagger$, двойственные к нормам Ки Фана, и алгоритмы Fanions



Пусть $\|\cdot\| = \|\cdot\|_{\text{KF}-k}^\dagger$. Возьмём направление $\Delta = \sum_{i=1}^k \mathbf{u}_i \mathbf{v}_i^\top$. Его норма $\|\Delta\|_{\text{KF}-k}^\dagger = \max\{\frac{1}{k} \|\Delta\|_{\text{nuc}}, \|\Delta\|_{\text{op}}\} = \max\{\frac{1}{k} k, 1\} = 1$, и скалярное произведение

$$\begin{aligned} \langle \mathbf{M}^t, \Delta \rangle &= \langle \mathbf{U} \Sigma \mathbf{V}^\top, \sum_{i=1}^k \mathbf{u}_i \mathbf{v}_i^\top \rangle = \sum_{i,j=1}^{r,k} \langle \mathbf{u}_i \sigma_i \mathbf{v}_i^\top, \mathbf{u}_j \mathbf{v}_j^\top \rangle = \sum_{i=1}^k \sigma_i \\ &= \|\mathbf{M}^t\|_{\text{KF}-k} = \|\mathbf{M}^t\|_{\text{KF}-k}^{\dagger\dagger} = \|\mathbf{M}^t\|^\dagger. \end{aligned}$$

Следовательно, искомое обновление для Fanion- k принимает вид:

$$\mathbf{X}^{t+1} = \mathbf{X}^t - \gamma_t \sum_{i=1}^k \mathbf{u}_i \mathbf{v}_i^\top$$

Ограничения на сингулярные числа в ЛМО с нормами Ки Фана и двойственными к ним



$\mathcal{B}_1$ для нормы Ки Фана ранга $k = 2$ и для двойственной к ней norme

$$\|\cdot\|_{\text{KF}-k}^\dagger = \max \left\{ \frac{1}{k} \|\cdot\|_{\text{нuc}}, \|\cdot\|_{\text{op}} \right\} .$$

Коническая комбинация LMO

Лемма о конической комбинации LMO алгоритмов (Кравацкий, 2025)

Пусть задано конечное семейство LMO-алгоритмов $i = 1, \dots, n$, где обновление i -го алгоритма на шаге t определяется как

$$\mathbf{X}^{t+1} - \mathbf{X}^t = \gamma_t \text{LMO}_{\|\cdot\|_{(i)}}(\mathbf{M}^t),$$

и $\text{LMO}_{\|\cdot\|_{(i)}}$ соответствует единичному шару нормы $\|\cdot\|_{(i)}$.

Тогда для любых неотрицательных $\alpha_1, \dots, \alpha_n$, алгоритм с обновлением

$$\mathbf{X}^{t+1} - \mathbf{X}^t = \gamma_t \sum_{i=1}^n \alpha_i \text{LMO}_{\|\cdot\|_{(i)}}(\mathbf{M}^t)$$

сам является LMO-алгоритмом, соответствующим единичному шару нормы, двойственной к норме $\sum_{i=1}^n \alpha_i \|\cdot\|_{(i)}^\dagger$.

Гибридные алгоритмы: F-Fanions и S-Fanions


$\alpha \times \text{Fanion}$ (норма $\|\cdot\|_{\text{KF-k}}^\dagger$) + $(1 - \alpha) \times \text{NSGD}$ (норма $\|\cdot\|_{\text{F}}$) =
F-Fanion:

$$\mathbf{X}^{t+1} = \mathbf{X}^t - \gamma_t \left(\alpha \sum_{i=1}^k \mathbf{u}_i \mathbf{v}_i^\top + (1 - \alpha) \frac{\mathbf{M}^t}{\|\mathbf{M}^t\|_{\text{F}}} \right)$$


$\alpha \times \text{Fanion} + (1 - \alpha) \times \eta \times \text{SignSGD}$ (норма $\eta \|\cdot\|_{\infty}$) = **S-Fanion**:

$$\mathbf{X}^{t+1} = \mathbf{X}^t - \gamma_t \left(\alpha \sum_{i=1}^k \mathbf{u}_i \mathbf{v}_i^\top + (1 - \alpha) \eta \text{sign}(\mathbf{M}^t) \right)$$

Число итераций до $F(\mathbf{X}) \leq 10^{-3}$ для гладкой выпуклой F при постоянном learning_rate




$F(\mathbf{X})$




$\|\nabla F(\mathbf{X})\|_F$

Задача: $F(\mathbf{X}) = \frac{1}{2} \|\mathbf{M}^{1/2} \mathbf{X} \mathbf{N}^{1/2}\|_F^2 \rightarrow \min_{\mathbf{X} \in \mathbb{R}^{500 \times 500}}$, где $\lambda(\mathbf{M}), \lambda(\mathbf{N}) \sim U[0, 1]$, $\mathbf{X}_{ij}^0 \sim \mathcal{N}(0, 1)$.

Обучение CNN: CIFAR-10 airbench




Точность на обучающей выборке




Точность на валидационной выборке

LMO-шары алгоритмов на CIFAR-10 airbench




$\mathcal{B}_{\text{learning_rate}}$ для норм, порождающих Muon и F-Muon

F-Muon на CIFAR-10 airbench: зависимость от α




Гиперпараметры оптимальны для Muon
(Keller, 2023)




Гиперпараметры оптимальны для F-Muon
с $\alpha = 0.5$

❗ F-Fanion с параметром $\alpha > 1$ не является LMO-алгоритмом.

Предобучение NanoGPT и GPT-2 Medium на FineWeb



Модель NanoGPT



Модель GPT-2 Medium

Выносятся на защиту

1. Обобщение алгоритма Muon до семейства алгоритмов Fanions на основе норм, двойственных к нормам Ки Фана
2. Лемма о том, что коническая комбинация LMO-алгоритмов является LMO-алгоритмом
3. Гибридные семейства алгоритмов F-Fanions и S-Fanions, объединяющие обновление Fanions с Normalized SGD и SignSGD
4. Показано, что F-Muon и S-Muon сопоставимы с Muon на задачах обучения свёрточных сетей (CIFAR-10 airbench) и трансформеров (NanoGPT, GPT-2).

Список работ автора по теме ВКР

1. **Kravatskiy A.** et al. The Ky Fan Norms and Beyond: Dual Norms and Combinations for Matrix Optimization // *International Conference on Computational Optimization, 2025 & Special Issue: Computational Optimization for Machine Learning and Data Science in Journal of Optimization Theory and Applications* (Q1) (на рецензировании)

Список литературы I

-  Bernstein, Jeremy и др. (2018). “signSGD: Compressed optimisation for non-convex problems”. В: *International conference on machine learning*. PMLR, с. 560—569.
-  Cesista, Franz Louis (февр. 2025). *Steepest Descent Under Schatten- p Norms*. URL:
<https://leloykun.github.io/ponder/steepest-descent-schatten-p/>.
-  Cutkosky, Ashok, Harsh Mehta и Francesco Orabona (2020). “Momentum-based variance reduction in nonconvex SGD”. В: *Advances in Neural Information Processing Systems*.
-  Hazan, Elad, Kfir Levy и Shai Shalev-Shwartz (2015). “Beyond convexity: Stochastic quasi-convex optimization”. В: *Advances in neural information processing systems* 28.

Список литературы II

-  Jordan, Keller и др. (2024). *Muon: An optimizer for hidden layers in neural networks*. URL: <https://kellerjordan.github.io/posts/muon/>.
-  Keller, Jordan (2023). *cifar10-airbench*. URL: <https://github.com/KellerJordan/cifar10-airbench>.
-  Kravatskiy, Alexey и др. (2025). *The Ky Fan Norms and Beyond: Dual Norms and Combinations for Matrix Optimization*. arXiv: 2512.09678 [math.OC]. URL: <https://arxiv.org/abs/2512.09678>.
-  Pethick, Thomas и др. (2025a). “ ν SAM: Memory-Efficient Sharpness-Aware Minimization via Nuclear Norm Constraints”. B: *Transactions on Machine Learning Research*. ISSN: 2835-8856. URL: <https://openreview.net/forum?id=V6ia5hWIMD>.

Список литературы III



Pethick, Thomas и др. (2025b). “Training Deep Learning Models with Norm-Constrained LMOs”. В: *Forty-second International Conference on Machine Learning*. URL: <https://openreview.net/forum?id=20qm2IzTy9>.



Shi, Hao-Jun Michael и др. (2016). “A primer on coordinate descent algorithms”. В: *arXiv preprint arXiv:1610.00040*.